

Análisis de la gastronomía asiática en Europa con foco en España

Trabajo Fin de Máster — Big Data, Data Science e Inteligencia Artificial (UCM Online)

Alumno: Peng Chen **Tutores:** Carlos Ortega y Santiago Mota **Opción:** Opción 1 — Análisis de un dataset (orientación Data Scientist) **Fecha:** Septiembre 2026

Índice

1. [Introducción y motivación](#)
 2. [Descripción del dataset y fuentes de datos](#)
 3. [Análisis Exploratorio de Datos \(EDA\)](#)
 4. [Preprocesamiento y transformación de datos](#)
 5. [Modelización](#)
 6. [Productivización del modelo](#)
 7. [Conclusiones y líneas futuras](#)
 8. [Bibliografía](#)
-

1. Introducción y motivación

La gastronomía asiática (china, japonesa, tailandesa, coreana, vietnamita, india, entre otras) es una de las categorías con mayor presencia y crecimiento en el sector de la restauración europea de las últimas décadas. Sin embargo, la información sobre su distribución geográfica, la diversidad de propuestas culinarias y los factores que determinan el éxito de un restaurante suele estar dispersa y no analizada de forma sistemática.

Este TFM tiene como objetivo caracterizar la presencia de la gastronomía asiática en Europa, con especial atención a España, y **construir un modelo predictivo capaz de estimar la valoración media que recibiría un restaurante asiático** en función de sus características (tipo de cocina, ubicación, rango de precio, sub-puntuaciones de comida/servicio/ambiente, etc.).

Objetivos específicos:

1. Analizar la distribución geográfica y los tipos de cocina asiática predominantes en Europa.

2. Identificar qué variables influyen más en la valoración (`rating`) de un restaurante.
3. Construir y comparar varios modelos de Machine Learning para predecir esa valoración.
4. Interpretar el modelo ganador con técnicas de explicabilidad (SHAP).
5. Productivizar el modelo en una función reutilizable que estime la valoración de un restaurante nuevo a partir de sus características.

El enfoque combina técnicas vistas a lo largo del máster: estadística descriptiva y regresión (Minería de Datos), modelos de árboles/ensemble y SVM (Machine Learning) y redes neuronales (Deep Learning), aplicadas de extremo a extremo sobre un caso de negocio real.

2. Descripción del dataset y fuentes de datos

Fuente: [TripAdvisor European Restaurants](#) (Kaggle, licencia CC0 / scraping público de TripAdvisor, autor `stefanoleone992`).

Tamaño original: 1.083.397 restaurantes europeos, 42 atributos (nombre, ubicación, coordenadas, cocinas, rango de precio, horarios, valoración media, nº de reseñas, sub-puntuaciones de comida/ servicio/valor/ambiente, premios, etiquetas, etc.).

Filtro aplicado: se seleccionan únicamente los restaurantes cuya columna `cuisines` contiene alguna de las siguientes categorías asiáticas:

```
asian_cuisines = ['Chinese', 'Japanese', 'Thai', 'Korean',  
                 'Vietnamese',  
                 'Indian', 'Asian', 'Sushi', 'Dim Sum', 'Ramen',  
                 'Noodles']
```



Resultado: **86.306 restaurantes asiáticos (7,97 % del total)**, distribuidos por 40 países europeos.

Limitación relevante del dataset: el scraping se realizó en 2021 y no se ha actualizado desde entonces; no incluye fecha de apertura del restaurante. Se evaluó explícitamente si existía una fuente pública más reciente (más cercana a 2026) con escala y detalle comparables, y no se encontró ninguna — el detalle de esta búsqueda y sus implicaciones se recoge en el apartado de líneas futuras (sección 7).

3. Análisis Exploratorio de Datos (EDA)

3.1 Distribución geográfica de restaurantes asiáticos en Europa



Reino Unido, Francia, Alemania, España e Italia concentran la mayor parte de la oferta de restaurantes asiáticos en Europa. España cuenta con **8.295 restaurantes asiáticos**, con **Madrid** muy por delante del resto de ciudades (1.000), seguida de Palma de Mallorca (218) y Las Palmas de Gran Canaria (108).



Se generó además un **mapa interactivo** con la geolocalización de los 86.306 restaurantes ([anexos/mapa_restaurantes_asiaticos.html](#)), disponible como material complementario.


3.2 Tipos de cocina asiática predominantes por país

La cocina china y la etiqueta genérica "Asian" son las más frecuentes en el conjunto, seguidas de la japonesa/sushi y la india. La distribución por país varía: por ejemplo, la cocina india tiene mayor peso relativo en Reino Unido (herencia de la inmigración histórica desde el sur de Asia), mientras que la cocina japonesa/sushi está más repartida de forma homogénea entre los principales países.




3.3 Análisis de valoraciones y reseñas


La valoración media (`avg_rating`) sigue una distribución sesgada hacia valores altos (media 3,99, mediana 4,0, en una escala de 1 a 5) — un patrón habitual en plataformas de reseñas como TripAdvisor, donde los usuarios tienden a puntuar más los establecimientos que les han gustado.



La correlación entre el **número de reseñas** y la **valoración media** es prácticamente nula ($r = 0,077$): tener muchas reseñas no implica una mejor valoración, simplemente mayor visibilidad.



La matriz de correlación muestra que las variables más asociadas con `avg_rating` son las sub-puntuaciones que el propio TripAdvisor calcula: `food` (0,81), `service` (0,78), `value` (0,74) y `atmosphere` (0,63).



4. Preprocesamiento y transformación de datos


Los datos brutos, tal como se descargan, no están listos para entrenar un modelo: hay huecos sin rellenar, columnas que no aportan información útil (o que directamente "hacen trampa", como se ve más abajo) y variables de texto que hay que convertir a números. Este apartado resume ese trabajo de limpieza y transformación.

Limpieza:

- Se eliminan las 4.991 filas sin `avg_rating` (variable objetivo), quedando 81.315 restaurantes.
- Se descartan columnas de texto libre no estructurado (`keywords` , `top_tags` , `awards` , `features` , dirección, enlaces...), columnas con fuga de información (`excellent` , `very_good` , `average` , `poor` , `terrible` — son conteos derivados del propio rating, así que dárselas al modelo sería "regalarle la respuesta") y columnas de altísima cardinalidad sin procesar (`city` , `province`).
- Hallazgo relevante:** `popularity_generic` resultó ser, tras inspección, un identificador de texto casi único por restaurante (81.161 valores distintos en 81.315 filas, del tipo `"#5907 of 18480 places to eat in Paris"`). Incluirlo como variable categórica desestabilizaba por completo el modelo de Regresión Lineal

(generaba un R^2 negativo, es decir, peor que no predecir nada); además, el ranking de TripAdvisor se calcula a partir del propio rating, por lo que también sería fuga de información. Se excluyó del modelo.

- La variable `total_reviews_count`, muy asimétrica (la mayoría de restaurantes tiene pocas reseñas y unos pocos tienen miles), se transforma matemáticamente (`log1p`) en vez de eliminar los casos extremos, para no perder información.



Feature engineering (construcción de variables a partir de los datos originales, para que el modelo pueda aprovecharlas):

- Variables binarias (Sí/No $\rightarrow$ 1/0): reclamado (`claimed`), apto vegetariano/vegano/sin gluten.
- `price_level` (€ / €€-€€€ / €€€€) codificado como variable ordinal (1-3), es decir, como un número que respeta el orden creciente de precio.
- `meals` (Lunch, Dinner, Breakfast...) y `cuisines` (tipos de cocina asiática) transformados en columnas Sí/No independientes (p. ej. "¿sirve cena?", "¿es cocina china?"), más un conteo `n_cuisines` del número de cocinas ofrecidas.
- País agrupado en los 15 más frecuentes + categoría "Otros", para evitar crear cientos de columnas minúsculas por países con muy pocos restaurantes.

Pipeline final (la secuencia de pasos que transforma los datos brutos en la tabla que ve el modelo): relleno de huecos (con la mediana en variables numéricas, con 0 en binarias, con el valor más frecuente en categóricas) + puesta en una escala común de las variables numéricas + conversión de categorías de texto en columnas 0/1 (*one-hot encoding*). Todo el proceso se ajusta **únicamente** con el 80 % de los datos reservado para entrenar, y se aplica igual al 20 % restante reservado para evaluar (`random_state=42`) — así se evita que el modelo "haga trampa" viendo de antemano los datos con los que luego será examinado.

5. Modelización

5.1 Predicción de valoración de restaurantes

Se plantea un problema de **regresión supervisada**: predecir `avg_rating` (escala 1-5) a partir de las características del restaurante (ubicación, tipo de cocina, rango de precio, sub-puntuaciones, horarios, etc.). El modelo se evalúa siempre sobre un **20 % de los datos que nunca ha visto durante el entrenamiento** (el "examen"), para asegurar que el resultado refleja cómo se comportaría con restaurantes nuevos y no simplemente que ha memorizado los datos de entrenamiento.


Cómo leer las métricas de esta sección:

- **RMSE y MAE**: el error típico de la predicción, expresado en la misma escala que el rating (1 a 5). Un MAE de 0,36, por ejemplo, significa que en promedio el modelo se equivoca en $\pm 0,36$ puntos sobre 5 — cuanto más bajo, mejor.
- **R²**: qué proporción de las diferencias de valoración entre restaurantes logra explicar el modelo, en una escala de 0 (no explica nada) a 1 (explica todo perfectamente). Un R² de 0,40 significa que el modelo capta una parte real pero no toda la variabilidad — el resto depende de factores no recogidos en los datos (por ejemplo, gustos subjetivos de cada cliente).

5.2 Comparativa de modelos

Se entrenan y comparan cinco modelos, eligiendo deliberadamente algoritmos vistos y practicados con código durante las distintas asignaturas del máster (Minería de Datos, Machine Learning y Deep Learning):

Modelo	RMSE	MAE	R ²	Asignatura
Regresión Lineal	0,548	0,375	0,372	Minería de Datos
Random Forest	0,557	0,365	0,349	Machine Learning
XGBoost (sin ajustar)	0,548	0,363	0,371	Machine Learning
SVR (Support Vector Regression)	0,560	0,368	0,344	Machine Learning
Red densa (Keras)	0,540	0,362	0,389	Deep Learning




Los cinco modelos obtienen resultados similares (R² entre 0,34 y 0,39), lo que indica que la relación entre las variables disponibles y la valoración es en gran parte lineal,

dominada por las sub-puntuaciones de comida, servicio y valor.

Modelo elegido para productivizar: XGBoost. Su rendimiento es prácticamente idéntico al de la red neuronal (diferencia de RMSE < 0,015, es decir, menos de 2 centésimas sobre una escala de 5), pero permite interpretabilidad nativa y rápida (ver 5.3) y no requiere el entorno de ejecución específico que necesita TensorFlow.


Tras un **ajuste de hiperparámetros** (probar de forma sistemática distintas configuraciones internas del modelo — 30 combinaciones, cada una validada con **validación cruzada**: se entrena y evalúa 5 veces sobre 5 particiones distintas de los datos, para confirmar que el resultado no depende de qué filas cayeron por azar en el conjunto de test) el RMSE de XGBoost mejora de 0,548 a **0,536**, y el R^2 sube de 0,371 a **0,399**. Esa misma validación cruzada confirma que el modelo es estable: el error apenas varía entre las 5 particiones (RMSE = $0,534 \pm 0,004$).




5.3 Interpretabilidad del modelo (SHAP)

Un modelo que predice bien pero no explica *por qué* es difícil de defender ante negocio.

SHAP es una técnica que, para cada predicción, reparte el "mérito" entre las variables de entrada — permite responder a la pregunta "¿qué ha hecho que el modelo prediga este rating y no otro?" tanto de forma agregada (qué variables importan en general) como para un restaurante concreto.





Conclusión de la interpretabilidad: las variables con mayor impacto en la valoración predicha son, por este orden, `food`, `service` y `value`, seguidas de `atmosphere` y el volumen de reseñas. El país y el tipo de cocina matizan la predicción pero con un peso claramente menor. Esto es coherente con la intuición de negocio: la calidad percibida de la comida y el servicio son, con diferencia, los factores que más determinan la reputación de un restaurante, por encima de dónde esté ubicado o qué tipo de cocina asiática ofrezca.

6. Productivización del modelo

El pipeline completo (preprocesamiento + modelo XGBoost afinado) se guarda con `joblib` y se envuelve en una función `predict_rating()` que recibe las características de un restaurante en lenguaje natural (sin que el usuario tenga que conocer el feature engineering interno) y devuelve la valoración media estimada:

```
predict_rating(  
    cuisines=['Japanese', 'Sushi'], country='Spain', price_level='€  
€€',  
    total_reviews_count=400, food=4.5, service=4.5, value=4.0,  
    atmosphere=4.5,  
)  
# → 4.32 / 5
```

Ejemplos de uso y resultado:

Escenario	Predicción
Japonés premium, buenas sub-puntuaciones, España	4,32 / 5
Chino económico, pocas reseñas, sub-puntuaciones mediocres, Reino Unido	2,83 / 5
Tailandés en Francia (sin especificar sub-puntuaciones, valores por defecto)	4,00 / 5

Cualquier parámetro no especificado toma automáticamente el valor mediano/modal del dataset de entrenamiento, por lo que la función es robusta ante información incompleta — un caso de uso realista, ya que un emprendedor evaluando la apertura de un restaurante nuevo raramente tendrá todos los datos de antemano.

Como línea de trabajo inmediata (fuera del alcance temporal de este TFM), esta función podría exponerse como una pequeña aplicación web con Streamlit o una API con FastAPI, ambas herramientas disponibles en el entorno de trabajo.

7. Conclusiones y líneas futuras

Conclusiones principales:

- La gastronomía asiática tiene una presencia significativa y heterogénea en Europa, concentrada en Reino Unido, Francia, Alemania, España e Italia, con Madrid como epicentro claro dentro de España.
- La cocina china y la etiqueta genérica "asiática" dominan la oferta, aunque con variaciones relevantes por país (p. ej. mayor peso de la cocina india en Reino Unido).
- La valoración de un restaurante asiático está determinada principalmente por la calidad percibida de la comida, el servicio y la relación calidad-precio — no por su ubicación geográfica ni por el tipo concreto de cocina asiática que ofrezca.
- Un modelo XGBoost, con hiperparámetros ajustados, predice la valoración media con un error medio (MAE) de 0,355 puntos sobre una escala de 1 a 5 — suficientemente preciso para un caso de uso de apoyo a la decisión (p. ej. estimar el potencial de éxito de un restaurante antes de abrirlo).

Líneas futuras:

1. **Actualidad de los datos:** este dataset fue recopilado en 2021 y no se ha vuelto a actualizar. Se buscó explícitamente una fuente pública más cercana a 2026 con escala y detalle comparables (más de 80.000 restaurantes asiáticos, con tipo de cocina, rating desglosado y geolocalización) y no se encontró ninguna — la alternativa más reciente localizada en Kaggle resultó tener solo 7 restaurantes y 1.502 reseñas, insuficiente para sustituir o complementar de forma fiable el análisis. Como continuación de este trabajo, se proponen tres vías: (a) series de interés de búsqueda en Google Trends como proxy de demanda reciente; (b) conteos actuales de restaurantes vía Google Places API u OpenStreetMap, comparables como "foto fija" 2026 frente a la de este dataset (2020-2021); (c) un scraping propio con fecha de alta del restaurante, que permitiría reconstruir una serie temporal real de aperturas.
 2. **Explotación del texto libre:** el dataset incluye una columna `keywords` con extractos de reseñas que no se ha explotado en este TFM. Aplicar técnicas de NLP (embeddings, fine-tuning de un modelo tipo DistilBERT, visto en la asignatura de Inteligencia Artificial) permitiría incorporar análisis de sentimiento como feature adicional del modelo.
 3. **Despliegue real:** convertir la función `predict_rating()` en una aplicación web (Streamlit) o API (FastAPI) accesible públicamente, con la interpretabilidad SHAP integrada para explicar cada predicción al usuario final.
-

8. Bibliografía

- Leone, S. (2021). *TripAdvisor European Restaurants* [Dataset]. Kaggle. <https://www.kaggle.com/datasets/stefanoleone992/tripadvisor-european-restaurants>
 - Pedregosa, F. et al. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*, 12, 2825-2830.
 - Chen, T., & Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*.
 - Abadi, M. et al. (2015). *TensorFlow: Large-Scale Machine Learning on Heterogeneous Systems*. tensorflow.org
 - Lundberg, S. M., & Lee, S.-I. (2017). A Unified Approach to Interpreting Model Predictions. *Advances in Neural Information Processing Systems*, 30.
 - Material docente del Máster en Big Data, Data Science e Inteligencia Artificial (UCM Online): asignaturas de Minería de Datos, Machine Learning y Deep Learning.
-

El código completo de todas las fases (carga, EDA, preprocesamiento, modelización, interpretabilidad y productivización) se encuentra documentado y ejecutado en los

notebooks del anexo (`anexos/01_carga_exploracion.ipynb` a `anexos/04_modelizacion_avanzada.ipynb`).